



한국차세대컴퓨팅학회 논문지 Vol.11 No.5

ISSN : 1975-681X(Print)

통합 전자전에서 기계학습을 이용한 위협체 역추정 모델링

하지수, 노상욱, 박소령

To cite this article : 하지수, 노상욱, 박소령 (2015) 통합 전자전에서 기계학습을 이용한 위협체 역추정 모델링, 한국차세대컴퓨팅학회 논문지, 11:5, 43-52

① earticle에서 제공하는 모든 저작물의 저작권은 원저작자에게 있으며, 학술교육원은 각 저작물의 내용을 보증하거나 책임을 지지 않습니다.

② earticle에서 제공하는 콘텐츠를 무단 복제, 전송, 배포, 기타 저작권법에 위반되는 방법으로 이용할 경우, 관련 법령에 따라 민, 형사상의 책임을 질 수 있습니다.

www.earticle.net

통합 전자전에서 기계학습을 이용한 위협체 역추정 모델링

Modeling the Reverse Extrapolation of RF threats Using Machine Learning Algorithms in Simulated Electronic Warfare Settings

하지수*, 노상욱^{*1)}, 박소령**

Jisu Ha, Sanguk Noh, So Ryoung Park

(14662) 경기도 부천시 원미구 지봉로 43 가톨릭대학교 컴퓨터정보공학부 *

(14662) 경기도 부천시 원미구 지봉로 43 가톨릭대학교 정보통신전자공학부 **

hajisu01@catholic.ac.kr, sunoh@catholic.ac.kr, srpark@catholic.ac.kr

요 약

본 논문은 통합전자전 상황에서 전자정보 수집신호의 변수를 분석하여 전자파 신호를 발산하는 레이더 및 위협체계를 역변환으로 모델링하는 기법을 다루고자 한다. 전자전 수신기가 위협체로부터 수신한 변수 중 가장 중요한 속성을 1-rule 알고리즘을 통하여 파악하였으며, 베이저안 분류 알고리즘, 의사결정 트리 학습 알고리즘 및 인공 신경망 알고리즘을 사용하여 위협체를 추정할 수 있는 프로토타입을 구축하였다. 다양한 통합전자전 상황에서 생성한 규칙을 기반으로 역변환 모델을 구축하고 새로운 데이터가 주어지면 모델링한 위협체로 분류한다. 실험에서 베이저안 분류 알고리즘, 의사결정 트리 학습 알고리즘 및 인공 신경망 알고리즘을 각각 적용하여 학습 곡선을 생성하였으며, 학습 곡선에서 최적의 성능을 나타내는 역변환 모델을 실험적으로 정립하였다. 또한, 세 가지 알고리즘의 결과로 생성된 프로토타입을 기반으로 역변환 모델링에 대한 정확도를 평가하였다.

Abstract

This paper proposes a method to model the reverse extrapolation of RF threats through the attributes representing RF threats in an integrated electronic warfare situation. Using 1-rule algorithm, the most important attribute figuring out the threat could be assured among the attributes which a receiver collected. And also, we build a prototype which estimates threats using three machine learning algorithms, i.e., naive Bayesian classifier, decision tree, and artificial neural network. In various integrated electronic warfare situations, we tested our reverse extrapolation model based on the outputs of machine learning algorithms, where new test data

1) 교신저자

※ 본 연구는 2015년도 가톨릭대학교 교비연구비(M-2015-B0002-00065)와 2013년도 국방특화연구센터 기초연구인 “전자전 수집 신호변수를 사용한 역변환모델링 연구(EW-41)” 과제의 지원으로 이루어졌음.

were given to identify a threat. We also generated learning curves for each algorithm, and experimentally decided their optimal reverse extrapolation models. To verify the prototype of our model compiled, we evaluated the accuracy of reverse extrapolation models and the resulting performance showed more than 99% of accuracy.

키워드: 통합전자전 M&S, 위협체 역추정, 베이저안 분류 알고리즘, 의사결정 트리 학습 알고리즘, 인공신경망 알고리즘

Keyword: Electronic Warfare M&S, Inverse Extrapolation Approach to Model Threats, Bayesian classifier, Decision Tree, Neural Network

1. 서론

현대전에서 레이더를 포함한 전자전 장비들은 적군의 위협을 탐지하는 역할 뿐만 아니라 적으로부터 아군을 보호하는 목적으로도 사용된다. 적군의 다양하며 복합적인 위협이 존재하는 통합전자전 상황에서 아군은 다중/복합 스펙트럼 위협을 식별하기 위하여 지휘통제 모듈의 여러 장비를 운용하고, 이들 장비는 각각의 특성에 따른 위협을 분석하는 임무를 수행한다. 아군의 생존 확률을 높이고 주어진 임무를 성공적으로 수행하기 위해서는 이러한 전자전 장비에서 수신한 데이터를 종합하여 상호 연관성을 분석하고, 분석한 데이터를 기반으로 위협에 대한 정보를 추출하여 지휘통제 모듈의 운용에 필수적인 정보를 생산할 수 있는 역변환모델링 기법에 대한 연구가 필요하다.

본 연구에서는 1-rule 알고리즘[1]을 사용하여 전자전 수신기에서 수신한 변수 중 가장 중요한 속성을 파악한다. 위협을 역추정하는 것은 해당 위협과 관련성이 높은 하나 혹은 다수의 정보들에 모델링한 위협체를 대응시키는 것과 같다. 본 논문에서는 위협체를 역추정하기 위하여 베이저안 분류[2], 의사결정 트리 학습[3-4] 알고리즘 및 인공 신경망 알고리즘[3] [5]을 이용하는 방법을 제안한다. 역추정을 위하여 전자전 수신기에서 수집 가능한 속성을 조사하고 레이더 및 위협체의 종류에 따른 속성들을 정리하였다. 조사한 위협체의 종류 별 속

성 값을 바탕으로 임의의 데이터 집합 3,000개를 생성하였으며, 역추정 알고리즘을 적용하고 분류 정확도를 측정하는 실험을 진행하였다. 또한 알고리즘 별 학습 곡선을 생성하여 각 알고리즘이 최적의 성능을 나타내는 역추정 모델을 정립하였다. 실험에서 각각의 역추정 모델에 대한 정확도를 평가하고 분석하였다.

2. 관련연구

전자전(Electronic Warfare)이란 상대방의 전투기/무기를 제어하기 위한 전자 시스템을 탐지하고, 이를 전자적으로 공격하거나, 역으로 상대방의 전자적인 공격에 대하여 우리의 전자 시스템을 방어하는 것을 의미하며, 군사적으로는 전자와 스펙트럼을 통제하기 위한 군사행동으로 정의되어 있다 [6]. 전자전을 다룬 연구로는 전자 공격에 대응하기 위하여, 전자 보호 및 사이버 방어 기술이 고려된 전자전 기술에 대한 연구가 수행되었다[7]. 본 논문은 이러한 전자전 환경에서 자율적인 상황인식에 초점을 두고 수행한 연구이다. 위협체의 인지 및 추정을 위한 전자전과 관련된 선행연구로는 전장 상황에서 위협 데이터를 수신하여 자율적으로 위협을 분류하고 통합하는 다중센서 위협 시뮬레이터를 제안 및 구현하는 연구[8] [9]가 진행되었다. 또한 항공기가 자신을 위협하는 위협에 대해 확인하고 최적의 대응방안을 선정하기 방법론을 제시한 연구 [10]가 수행되었다. 본 연구에서는 이러한 선행연

구를 확장하여 RF 위협의 정체를 분석하고 역추정하며, 역추정 결과에 대한 정확도의 분석에 중점을 둔다.

본 연구에서는 위협을 역추정하기 위하여 다양한 기계학습 알고리즘을 사용한다. 기계학습(Machine Learning)은 “환경과의 상호작용에 기반한 경험적인 데이터로부터 스스로 성능을 향상시키는 시스템을 연구하는 기술”로 정의된다[11]. 인공지능 분야의 핵심 기반 기술 중의 하나로써 기계학습은 인터넷 정보검색[12], 텍스트 마이닝[13], 생물정보학[14], 자연어 처리[15], 영상처리 및 분류[16][17], 시뮬레이션을 통한 동적인 행위 계획[18], 군관련 응용 분야에서 적군의 주타격 방향을 분류한 연구[19] 등의 다양한 응용분야에서 활용되고 있다. 이러한 다양한 분야에서 활용되고 있는 기계학습 방법 중에서 통계적 모델을 제공하는 나이브 베이저안 분류 알고리즘, 결과 모델을 트리형태로 나타내는 의사결정 트리 학습 알고리즘, 그리고 비지도 학습 방식으로 대표적인 인공 신경망 알고리즘을 위협체의 인지 및 분류를 위하여 사용한다. 다양한 분야에서 이러한 기계학습 방법을 활용하여 주어진 도메인의 특징을 나타내는 지식을 추출하는 점에서 본 연구와 유사하며, 군사적인 도메인(military domain)의 하나인 통합 전자전 환경에서 위협체의 역변환 모델을 제시하기 위한 방법론으로 활용한 점에서 차이점을 갖는다.

3. 위협체 역변환 모델링

3장에서는 수신기에서 수신된 자료를 기반으로 위협체에 대한 속성을 분석한다. 위협체에 대한 수신변수를 입력받아 위협체를 역으로 확인할 수 있는 역변환 모델링 기법을 알아본다.

3.1 위협체 속성 분석

통합전자전 상황에서 식별 가능한 위협에 대하여 문헌조사[20]를 통해 표 1과 같이 정리하였다. 위협을 역추정하기 위한 속성으로는 주파수 대역

(Radio Frequency: RF), 펄스 폭(Pulse Width: PW), 펄스 반복 주기(Pulse Repeat Interval: PRI), 펄스 전력(Pulse Power: PP)을 채택하였다. 위협은 전자전 수신기에서 수집할 수 있는 속성을 이용하여 ‘탐지 레이더,’ ‘추적 레이더,’ ‘레이더 유도 미사일 탐색기’로 모델링 하였다.

〈표 1〉 위협체 속성

속성	유형	단위
주파수 대역	numeric	Hz
펄스 폭	numeric	μs
펄스 반복 주기	numeric	μs
펄스 전력	numeric	kW

3.2 속성 분석 및 역추정 알고리즘

3.2.1 1-rule을 이용한 속성 분석

1-rule은 하나의 속성으로 구성된 분류 규칙을 인스턴트 집합으로부터 찾아내는 방법이다. 다시 말하면, 모든 속성의 속성 값에 대하여 가장 빈도수가 높은 클래스를 찾고, 에러율이 가장 작은 하나의 속성을 대표 규칙으로 선택하게 된다.

각 속성은 속성 값의 갯수 만큼 규칙 집합을 생성하고, 각각의 속성에 의하여 생성된 규칙 집합은 특정한 인스턴스(instance)를 분류한다. 이때, 각 속성의 관점에서 전체 인스턴스를 분류한 결과의 에러율을 계산할 수 있으며, 모든 속성 중에서 가장 작은 에러율을 갖는 하나의 속성에 대한 규칙을 최종적으로 선택한다. (그림 1)은 1-rule 알고리즘을 의사코드 형태로 보여준다.

각 속성에 대하여 아래 과정을 반복한다:
 특정한 속성의 값에 대하여,
 다음과 같이 규칙을 작성한다:
 가장 빈도수가 높은 클래스를 찾는다.
 선택된 속성 값에 대한 규칙을 생성한다.
 생성한 규칙의 에러율을 계산한다.
 최종적으로 가장 작은 에러율을 갖는 하나의 규칙을 선택한다.

(그림 1) 1-rule의 동작 절차를 나타낸 의사코드

3.2.2 베이지안 분류 알고리즘

베이지안 분류 알고리즘은 지도 학습의 일종으로 조건부 확률을 기반으로 한 베이지안 규칙을 통하여 데이터를 분류하는 알고리즘이다. 베이지안 분류 알고리즘을 사용한 분류기는 훈련 데이터를 학습하여 규칙을 생성한다. 그리고 학습된 규칙을 이용하여 새로운 데이터가 어떤 클래스에 속할 지에 대하여 예측 및 판단한다. $F = \{f_1, f_2, \dots, f_n\}$ 는 다중 속성의 집합이며, $C = \{c_1, c_2, \dots, c_m\}$ 는 클래스의 집합이라고 가정하면, 베이지안 규칙은 식 (1)과 같이 표현할 수 있다.

$$P(c_j|f_i) = \frac{P(f_i|c_j) P(c_j)}{\sum_{j=1}^m P(f_i|c_j) P(c_j)} \quad (1)$$

$P(c_j|f_i)$ 는 주어진 다중 속성 f_i , $f_i \in F$ 에 대한 클래스 c_j , $c_j \in C$ 의 사후 확률(posterior probability)이다. 본 논문에서 다중 속성 집합 F 는 표 1에서 정리한 속성들을 사용하였으며, 클래스 C 는 모델링한 위협체를 사용하였다. $P(c_j|f_i)$ 는 다음과 같이 구해진다. 모든 클래스 c_j , $c_j \in C$ 에 대하여 다중 속성 F 의 각 속성 f_i 에 대한 사후 확률인 $P(f_i|c_j)$ 을 구한다. 수치형 속성인 경우에는 정규분포를 따르는 확률 밀도함수를 이용하여 확률을 계산한다. 수식 (1)의 분자에 나타난 바와 같이 $P(f_i|c_j)$ 와 클래스 c_j 의 사전 확률(prior probability)을 곱하여, 수식 (1)의 분모에 표시한 정규화과정을 거치면 $P(c_j|f_i)$ 를 구할 수 있다. 따라서, 임의의 상황에서 특정한 속성 값에 대하여 가장 큰 $P(c_j|f_i)$ 확률 값을 가지는 클래스 c_j 가 정해진다.

3.2.3 의사결정 트리 학습 알고리즘

의사결정 트리 학습 알고리즘은 엔트로피 이론과 정보 이득을 사용하여 분류 기준을 생성하는 알고리즘이다. 엔트로피(entropy)는 주어진 데이터 집합의 혼잡도를 의미하며 0에서 1사이의 값을 갖는다. 가장 혼잡도가 높은 상태의 값이 1이며, 하나의

클래스로만 구성된 상태의 값이 0이다. 의사결정 트리 학습 알고리즘은 주어진 데이터 집합과 고려하는 속성 중에서 엔트로피가 가장 낮은 속성을 찾아가는 과정이다. 엔트로피 값은 다음 식 (2)에 의하여 계산된다[3-4].

$$I(P(v_1), \dots, P(v_n)) = \sum_{i=1}^n -P(v_i) \log_2 P(v_i) \quad (2)$$

위의 식 (2)은 주어진 속성 v_1, \dots, v_n 을 가지는 집합에 대한 엔트로피 값을 구하는 계산식이다. $P(v_i)$ 는 속성 v_i 의 확률이고 n 은 속성의 개수이다.

정보 이득(information gain)이란 어떠한 속성이 예제 인스턴스의 전체 집합을 가장 효율적으로 구분할 수 있는가를 정량적으로 나타낸다. 정보이득을 계산하기 위해서는 엔트로피의 계산방법(식 (2) 참조)이 필요하며, 정보 이득의 계산식은 다음 식 (4)와 같다[4].

$$Remainder(A) = \sum_{i=1}^v \frac{p_i + n_i}{p+n} I\left(\frac{p_i}{p_i + n_i}, \frac{n_i}{p_i + n_i}\right) \quad (3)$$

$$Gain(A) = I\left(\frac{p}{p+n}, \frac{n}{p+n}\right) - Remainder(A) \quad (4)$$


수식 (3)과 (4)에서 A 는 속성이며, 주어진 도메인을 두 개의 클래스로 구분할 때, p 는 포지티브 클래스의 데이터 개수이고, n 은 네가티브 클래스의 데이터 개수를 말한다. 또한, p_i 와 n_i 는 각각 속성 A 의 속성값(i)이 포지티브 클래스와 네가티브 클래스에 속한 데이터 개수를 의미한다. $Remainder(A)$ 는 A 속성에 대하여 v 개의 속성값을 가지며, 각 속성값에 대한 엔트로피를 계산한 후 속성값이 속한 데이터 집합의 개수를 가중치로 곱하여 v 개의 속성값에 대하여 합한 값이다. 따라서, $Remainder(A)$ 는 속성 A 에 의하여 데이터 집합이 분류되지 않고 남아있는 인스턴스들의 엔트로피를 나타낸다. 최종적으로 속성 A 의 정보이득을 나타내는 수식 (4)는 현재 데이터 집합의 엔트로피 값에서 속성 A 에 의하여 분류되지 않고 남아있는 인스턴스들의 엔트로피에 대한

차로 정의된다. 속성의 정보이득이 크다는 것은 특정 속성의 정보 분류 능력이 다른 속성보다 크다는 것을 의미한다. 엔트로피와 정보 이득을 사용하는 의사결정 트리를 통한 데이터 분석의 결과는 트리 구조로 표현되기 때문에 분석가가 결과를 쉽게 이해하고 설명할 수 있는 장점이 있다.

3.2.4 인공 신경망 알고리즘

인공 신경망 알고리즘은 인간의 뇌의 작동원리를 모방하여 설계한 알고리즘이다[21]. 인공 신경망은 단순한 선형 패턴 뿐만 아니라 복잡한 비선형 패턴까지 학습할 수 있어 높은 예측성능을 보이는 대표적인 인공지능 기법 중 하나이다.

인공 신경망은 보통 입력층(input layer), 출력층(output layer) 그리고 하나 이상의 은닉층(hidden layer)으로 구성된다. 각 층은 기본 단위인 다수의 뉴런(neuron)으로 구성된다. (그림 2)는 인공 신경망의 기본단위인 뉴런의 구조를 도식화한 그림이다.




(그림 2) 인공 신경망의 기본 단위인 뉴런의 구조

위 그림과 같이 뉴런은 일정 값($x_1, x_2, x_3, \dots, x_n$)을 입력받아 각 입력 값에 주어진 가중치($w_1, w_2, w_3, \dots, w_n$)를 곱하여 다음 식 (5)와 같이 합산 값(N)을 계산하고 식(6)과 같이 출력 값(Out)을 결정한다.

$$N = \sum_i^n w_i x_i \quad (5)$$


$$Out = f(N) \quad (6)$$

이 때, 합산 값(N)을 출력 값(Out)으로 변환시키는 함수 $f(x)$ 를 전이함수(transfer function)라고 한다. 이 전이함수에는 계단(hard limit) 함수, 임계(threshold) 함수, 그리고 S자 형태의 시그모이드(sigmoid) 함수 등이 적용될 수 있는데 일반적으로 (그림 3)과 같은 시그모이드 함수가 가장 많이 사용되고 있다.



(그림 3) 대표적인 시그모이드 함수(sigmoid function)

(그림 4)는 이러한 뉴런들로 이루어진 인공 신경망의 기본 구조이다. 각 층은 하나 이상의 뉴런으로 구성되어 있으며 뉴런은 연결 가중치를 가지고 다른 층의 뉴런과 연결되어 있다. 입력 층은 외부에서 입력 값을 받는 역할을 하고 출력 층은 신경망의 결과를 출력하는 역할을 한다. 입력 층과 출력 층 사이의 은닉 층은 직접적으로 결과를 출력하지는 않지만 신경망의 출력 값을 목표 값에 근접하게 한다.



(그림 4) 인공 신경망의 구조

인공 신경망 알고리즘의 처리 과정은 입력 층에 훈련 패턴을 제시하고 신경망 내의 연산을 거쳐 출력 층에 산출된 결과와 목표 값이 일치하도록 신경망 내의 연결 가중치를 조정한다.

4. 실험 및 분석

실험에서는 위협체 역추정을 위한 가장 중요한 속성을 판별하고 역추정 모델 생성을 위한 최적의 데이터 집합을 확인한다. 또한, 생성한 모델 간 성능 비교를 통하여 가장 우수한 모델을 선별한다.

4.1 1-rule 알고리즘을 이용한 중요 속성 분석

실험을 위해 생성한 임의의 3,000개의 데이터 집합은 모두 수치형 속성으로 이루어져 있기 때문에 간단한 이산화 작업을 통해 이산 속성으로 변환하여 사용할 수 있다. 먼저, 훈련 예제들을 수치형 속성 값에 따라 정렬한다. 그러면 클래스 값의 순서나 시퀀스가 만들어진다. 이산화 작업은 이런 시퀀스에 분기점들을 놓아 분할하는 작업을 수반한다. (그림 5)는 3,000개의 데이터 집합을 데이터 마이닝 툴인 Weka[21]를 사용해서 1-rule 알고리즘을 적용한 것이다. 표 1에 정의한 네 가지 속성 중에서 주파수 대역(RF) 속성의 정확도가 100%로 나타났다으므로 위협을 역추정하기 위한 가장 중요한 속성임을 알 수 있었다. 즉, 주파수 대역 속성은 주어진 훈련 예제들을 오류없이 세 가지의 클래스로 분류해 주었다.


```
RF:
    < 4.00177      -> search-radar
    < 8.013245     -> tracking-radar
    >= 8.013245    -> missile
(3000/3000 instances correct)
```

(그림 5) Weka를 이용한 1-rule 알고리즘 수행 결과

4.2 역추정 알고리즘 별 학습곡선

본 논문에서 사용된 세 가지 역추정 알고리즘의 정확도 비교 및 규칙을 생성하기 위한 최적의 데이

터 집합을 찾기 위해서 학습곡선(Learning curve)을 생성하고 비교하였다. 각 역추정 알고리즘에 대하여 임의로 생성한 3,000개의 트레이닝 인스턴스 중에서 180, 240, 300, ..., 900개의 13개 인스턴스 집합을 생성하였으며, Weka를 이용해 교차 검증(cross-validation) 모드로 수행하여 정확도를 측정하였다. 교차 검증 모드는 데이터의 양이 충분치 않을 때 분류기 성능 측정의 통계적 신뢰도를 높이기 위해 사용하는 방법 중 하나이다.



(그림 6) 세 가지 역추정 알고리즘의 학습곡선 비교

(그림 6)은 세 가지 역추정 알고리즘을 교차 검증 모드로 수행한 학습곡선을 비교한 것이다. 훈련 데이터의 각 그룹에 대하여 세 가지 알고리즘 모두 98%이상의 정확도를 나타내었으며, 전체 데이터 집합에서 베이지안 분류 알고리즘이 가장 높은 정확도를 보였다. 학습곡선을 통하여 세 가지 역추정 알고리즘 모두 각각의 역추정 모델을 생성하기 위한 최적의 인스턴스 집합이 480개임을 확인하였다.

4.3 역추정 알고리즘 성능 비교

ANOVA(Analysis of variance)는 통계학에서 두 개 이상 다수의 집단을 비교하고자 할 때 집단 내의 분산, 총 평균과 각 집단의 평균의 차이에 의하여 생긴 집단 간 분산의 비교를 통해 만들어진 F 분포를 이용하여 가설검증을 하는 방법이다. 본 논문에서는 각 알고리즘이 생성한 규칙의 성능차이가 통계적으로 유의한지를 판별하기 위하여 수행하였

다. 표 2는 ANOVA 테스트를 위하여 생성한 10개 데이터 집합에 대하여 각 알고리즘으로 수행한 정확도의 평균과 표준편차를 나타낸다. 이때, 각각의 데이터 집합은 (그림 6)의 학습곡선에 의하여 정해진 480개의 훈련 데이터로 이루어졌다.

〈표 2〉 ANOVA 테스트를 위한 각 알고리즘 별 정확도(%)

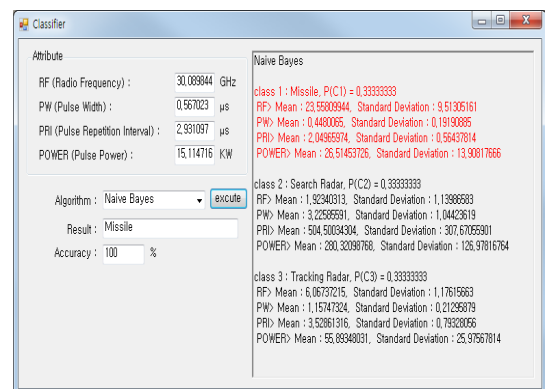
	베이지안 분류	의사결정 트리	인공 신경망
1	100	99.5833	100
2	99.7917	99.7917	99.7917
3	99.7917	99.5833	100
4	100	99.7917	99.7917
5	99.7917	99.375	100
6	99.7917	99.5833	99.5833
7	100	99.5833	99.7917
8	100	99.5833	99.7917
9	100	99.5833	100
10	100	99.5833	99.7917
평균	99.92 ± 0.1076	99.60 ± 0.118	99.85 ± 0.1406
f	19.045223		

모델링한 위협체의 데이터 집합을 토대로 ANOVA 테스트를 수행하였다. ANOVA 테스트를 위한 속성 값으로는 $k=3$ (역추정 알고리즘의 개수), $n=10$ (총 시행 횟수), $V_1=k-1=2$, $V_2=k(n-1)=27$ 이 사용 되었으며, 결과적으로 $f=19.045223$ 이 계산되었다. 따라서, f 값과 f 분포표를 참조하여 $f_{.05, 2, 27} = 2.902$ 이고 $f_{.01, 2, 27} = 3.913$ 이므로, $f > f_{.01, 2, 27} > f_{.05, 2, 27}$ 임을 알 수 있다. 따라서, 세 가지 역추정 알고리즘의 성능은 각각 95% 신뢰수준과 99%의 신뢰수준에서 통계적으로 유의한 결과를 나타낼 수 있다. 결론적으로 주어진 도메인에서 세 가지 역추정 알고리즘의 성능은 통계적으로 차이가 있으며, 베이지안 분류 알고리즘의 성능이 가장 뛰어남을 알 수 있다.

5. 위협체 역변환 모델 구현

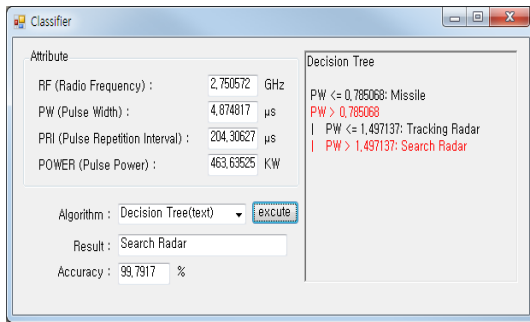
위협체 역변환 모델은 통합전자전 상황에서 전자전 수신기가 수신할 수 있는 속성 변수들을 기반으로 지도학습 및 비지도학습 알고리즘을 사용하여 구현하였다. 구현한 통합 시뮬레이터는 마이크로소프트사의 C# 4.0 언어와 오라클사의 JAVA 언어를 사용하였다. 표 1에 정리된 네 가지 속성 값의 범위 내의 값과 역추정 알고리즘을 선택하면, 각 알고리즘에 의한 역추정 결과 값을 확인할 수 있다.

(그림 7)은 나이브 베이지안 분류 알고리즘(naive Bayesian classifier)의 실행화면이다. 화면 좌측상단의 [Attribute]란에서 전자전 수신기에서 수신할 수 있는 변수 중 위협체 모델링에 사용했던 네 가지 속성을 입력하도록 구현하였다. 사용자는 표 1의 범위 중에서 임의의 값들을 대입할 수 있다. 속성 값을 입력한 후 [Execute] 버튼을 누르면 우측에 임의의 데이터 집합 3,000개 중 최적의 데이터 집합 480개로 생성된 나이브 베이지안 분류의 확률 값들과 각 속성 별 평균, 표준편차가 표기된다. 빨간색으로 표기된 부분은 입력한 속성 값들을 이용해서 역추정된 위협체에 해당하는 값이다. (그림 7)은 주어진 입력 값에 대하여 ‘레이더 유도 미사일 탐색기’ (Missile)로 역추정된 결과화면을 보여준다.



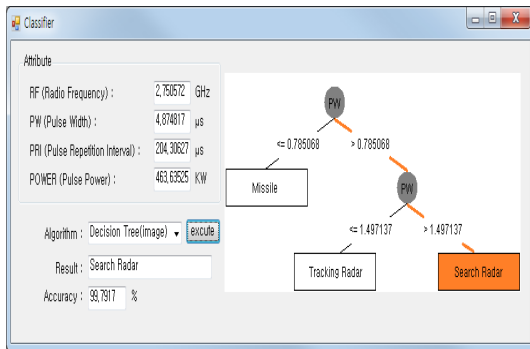
(그림 7) 나이브 베이지안 분류 알고리즘 실행화면

의사결정 트리 학습 알고리즘은 두 가지 버전으로 구현하였다. 첫 번째로 (그림 8)은 의사결정 트리 학습 알고리즘의 실행 결과를 Weka에서 수행한 결과의 형태로 표현한 화면이다. 위와 마찬가지로 속성으로 입력된 값들은 임의의 값들을 대입하였다. 실행 결과는 (그림 8)의 오른쪽 화면과 같이 텍스트로 표현되며 역추정된 위협체에 따라 조건에 부합하는 노드는 빨간색으로 표기된다.



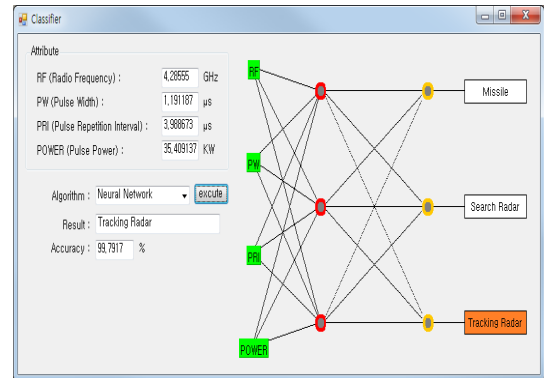
(그림 8) 의사결정 트리 학습 알고리즘 실행화면 (텍스트 모드)

두 번째로 (그림 9)는 의사결정 트리 학습 알고리즘의 실행결과를 가시성이 높은 트리 형태로 표현한 화면이다. 실행 결과는 (그림 9)의 오른쪽 화면과 같이 트리의 분기에서 조건에 맞는 노드를 따라 최종적으로는 위협체에 도달하도록 표기된다.



(그림 9) 의사결정 트리 학습 알고리즘 실행화면 (트리 모드)

(그림 10)은 인공 신경망 알고리즘의 실행화면이다. [Execute] 버튼을 누르면 Weka로부터 도출된 인공 신경망에 의해 모델링된 위협체 역추정을 수행한다. 역추정을 마치면 전체적인 인공 신경망의 구조와 분류된 결과가 오른쪽에 도식적으로 표시된다. 표 3은 도출된 인공신경망 내의 연결가중치 값을 표기한 것으로 w_{ij} 는 입력 층의 i 번째 노드와 은닉 층의 j 번째 노드 사이의 연결가중치 값을 의미한다.



(그림 10) 인공 신경망 알고리즘 실행화면

〈표 3〉 구축된 인공신경망 내의 연결가중치 값

입력층-은닉층 간 연결가중치 w_{ij}							
w_{11}	9.75	w_{21}	-7.58	w_{31}	0.45	w_{41}	-2.01
w_{12}	-10.72	w_{22}	7.84	w_{32}	5.72	w_{42}	3.21
w_{13}	-9.73	w_{23}	7.71	w_{33}	-0.56	w_{43}	2.17
은닉층-출력층 간 연결가중치 w_{jk}							
w_{11}	8.51	w_{21}	-2.87	w_{31}	-8.38		
w_{12}	-4.48	w_{22}	11.86	w_{32}	-0.58		
w_{13}	-8.38	w_{23}	-13.63	w_{33}	7.70		

6. 결론

본 논문은 통합전자전 상황에서 전자정보 수집신호의 변수를 분석하여 전자파 신호를 발산하는 레

이더 및 위협체계를 역변환으로 모델링하는 기법을 다루었다. 문헌조사를 통해 수집할 수 있는 속성 값에 따른 위협체를 모델링 하였으며, 모델링한 위협체로 역추정하기 위한 알고리즘의 성능을 실험적으로 분석하였다.

실험에서는 전자전 수신기가 위협체로부터 수신한 변수 중 1-rule 알고리즘을 통해 주파수대역(RF) 속성이 가장 중요한 속성임을 파악하였다. 또한, 수신기에서 수집한 변수를 이용하여 훈련 데이터 개수를 증가시키며 역추정 알고리즘의 정확도를 측정하기 위하여 학습곡선을 작성하고 이로부터 역변환 모델을 생성하기 위한 최적의 훈련 데이터 집합을 확인하였다. 지도학습과 비지도학습 알고리즘을 통하여 생성한 역변환모델의 성능 차이에 대한 유의성을 판별하기 위하여 ANOVA 테스트를 수행하였으며, 세 가지 모델의 성능비교에서 나이브 베이즈 분류기에 의한 역변환 모델의 성능이 가장 우수한 것으로 나타났다. 전자전 상황에서 위협체를 확인 및 역추정하기 위한 통합 시뮬레이터를 개발하기 위하여 실험에서 얻은 최적의 데이터 집합을 기반으로 세 가지 역변환 모델을 구현하였다.

앞으로 지속적인 연구를 통하여 개발한 역변환 모델을 모듈화하여 전체 통합전자전 시스템에 이식할 것이다. 또한, 수신된 레이더 정보에 대한 운영자의 분석없이 자율적으로 전장상황을 인식하기 위하여는 주어진 상황에 대한 정확한 판단이 이루어져야 하며, 이를 위하여 여러 가지 역변환 모델의 결과 값을 융합하여 하나의 결론으로 제시할 수 있는 방법을 연구할 것이다.

참고문헌

- [1] T.M. Mitchell, Machine Learning, McGraw-Hill, pp.154-198, 1997.
- [2] S.R. Safavian and D. Landgrebe, "A Survey of Decision Tree Classifier Methodology," IEEE Transactions on Systems, Man and Cybernetics, Vol. 21, No. 3, pp.660-674, 1991.
- [3] S. Russell and P. Norvig, Artificial Intelligence: A Modern Approach, 3/e, Pearson Education, Inc., pp.693-767, 2010.
- [4] M. A. Friedl and C. E. Brodley, "Decision tree classification of land cover from remotely sensed data," Remote Sensing of Environment, Vol. 61, pp.399-409, 1997.
- [5] M. Hagan, H. Demuth and M. Beale, Neural network design, <http://ecee.colorado.edu>, 1996.
- [6] 남상욱, "전자전 기술 동향", 한국전자과학회 전자파기술, 제24권 제6호, pp.1-2, 2013, 11.
- [7] 장재원, 안태남, 이광일, "전자보호 및 사이버 방어와 함께 진화하는 전자전 기술의 발전방향", 한국전자과학회 전자파기술, 제24권 제6호, pp.3-13, 2013, 11.
- [8] 박현우, 이규선, 최채택, 노상욱, "항공기 통합 전자전 장비의 운용효과도 측정을 위한 시뮬레이터 개발", 한국차세대컴퓨팅학회 논문지 제8권 제2호, pp.73-86, 2012, 4.
- [9] 하지수, 노상욱, "귀납적 기계학습 알고리즘을 이용한 위협체 역추정 기법", 한국정보과학회 학술발표논문집, pp.544-546, 2014, 12.
- [10] 박소령, 박현우, 하지수, 최채택, 정운섭, 노상욱, "자율적으로 결정한 대응기법의 운용효과도 설계", 한국인터넷정보학회 논문지 제13권 제4호, pp.11-21, 2012, 8.
- [11] 장병탁, "차세대 기계학습 기술", 정보과학회지, 제25권 제3호, pp.96-107, 2007, 3.
- [12] 박성배, 태운식, "기계학습과 정보검색", 정보과학회지 제25권 제3호, pp.5-11, 2007, 3.
- [13] 김천식, 정명희, 홍유식, "적응적인 학습을 위한 텍스트 마이닝 기술", 전자공학회논문지 CI편 제45권 제3호, pp.31-39, 2008, 5.
- [14] 김민수, 이승로, 서희돈, "퍼지-뉴럴 네트워크를 이용한 심전도 패턴 분류시스템 설계", 대한전자공학회 종합학술대회논문집 Vol.5 시스템 및 제어 소사이어티 제25권, 제1호, pp.273-276, 2002, 6.
- [15] 정석원, 최맹식, 김학수, "위키백과로부터 기계학습

- 기반 한국어 지식베이스 구축”, 정보과학회논문지 제 42권 제8호, pp.1065-1070, 2015. 8.
- [16] 이현규, 최민국, 신병석, 이상철, “명암도 조절을 통한 베이스 분류기 기반 영상분할기법”, 한국차세대컴퓨팅학회 논문지 제8권 제5호, pp.73-86, 2012. 10.
- [17] Whenming Shen, Guozeng Wu, Zhongping Sun, Wencheng Xiong, Zhuo Fu, Rulin Xiao, “Study on classification methods of remote sensing image based on decision tree technology”, IEEE Computer Science and Service System (CSSS), pp.4058-4061, 2011
- [18] 이효철, 이석원, “시뮬레이션의 동적인 행위 계획을 위한 통합 학습 방법”, 한국차세대컴퓨팅학회 논문지 제11권, 제2호, pp.49-65, 2015. 4.
- [19] 김무수, 박건우, 이상훈, “의사결정트리를 이용한 적군의 주타격 방향 분석”, 정보과학회논문지 : 소프트웨어 및 응용, 제40권 제1호, pp.37-44, 2013. 1.
- [20] S. Noh and U. Jeong, “Intelligent Command and Control Agent in Electronic Warfare Setting,” International Journal of Intelligent Systems, Vol. 25, Issue 6, pp. 514-528, 2010.
- [21] I.H. Witten, E. Frank and M.A. Hall, Data Mining, 3/e, Morgan Kaufmann, 2010.

■ 저자소개

◆ 하지수



- 2014년 가톨릭대학교 컴퓨터정보공학부 학사
- 2014년~현재 가톨릭대학교 컴퓨터정보공학부 석사과정
- 관심분야: 지능형 분산 시스템, 지식관리, 결정이론, 기계학습 등

◆ 박소령



- 2002년 한국과학기술원 전자전산학과 졸업(공학박사)
- 2003년~현재 가톨릭대학교 정보통신전자공학부 교수
- 2009년~현재 한국통신학회 논문지 편집위원
- 관심분야: 통계학적 신호처리, 무선통신, 다중접속 등

◆ 노상욱



- 1987년 서강대학교 생명과학 이학사
- 1989년 서강대학교 컴퓨터공학 공학석사
- 1999년 텍사스주립대학교 컴퓨터공학 공학박사
- 1989년~1995년 국방과학연구소 연구원
- 2000년~2002년 미조리주립대학교 컴퓨터학과 교수
- 2002년~현재 가톨릭대학교 컴퓨터정보공학부 교수
- 관심분야: 지능형 분산 시스템, 지식관리, 결정이론, 기계학습 등