

HMM과 신경망을 이용한 재밍기법 선택 방안 연구

홍석준*, 이연규*, 최종원*, 조제일**, 서보석*

*충북대학교, **국방과학연구소

Selection of Jamming Technique Using A HMM and Neural Network

Seok-Jun Hong, Yearn-Gui Yi, Jong-Won Choi, Jeil Jo, Bo-Seok Seo

Chungbuk National University, Agency for Defense Development

요 약

이 논문에서는 기계학습을 이용하여 수신된 레이더 신호로부터 추출한 데이터만으로 최적의 재밍기법을 선택하는 방식을 제안한다. 현재 군에서는 대부분 사전 조사에 의해 구축된 라이브러리를 기반으로 위협별 재밍기법을 선택하는 방식을 사용한다. 그러나 레이더 기술은 계속적으로 발전되고 다양해지고 있기 때문에 새로운 위협이나 기존의 라이브러리에 존재하지 않는 위협에 대해서 이 방법을 적용하는 경우 적절한 재밍기법을 선택하는데 제한이 따른다. 따라서 기존의 위협 라이브러리를 이용한 방식과 다르게 분석된 레이더 신호의 데이터만을 이용하여 최적의 재밍기법을 선택할 수 있는 기술이 필요하다. 이 연구에서는 새로운 위협 신호에 대응하기 위한 방법으로 기계학습을 기반으로 한 방법을 제시한다. 제안한 방법은 기존에 축적된 라이브러리 데이터를 이용하여 은닉 Markov 모델과 신경망으로 구성된 분류기를 학습시킴으로써 새로운 위협 신호에 대해 적응적으로 재밍기법을 선택할 수 있다.

1. 서 론

현대전은 전자장비에 크게 의존하게 되면서 전자기술은 군사작전에서 점점 더 중요하게 되었고, 다양한 주파수 스펙트럼을 사용하는 복잡한 전자전 환경에서 군사작전을 수행하게 되었다. 이와 같은 전자전 환경에서 적의 전파 이용을 제한하는 재밍 기술이 전자방해책의 중요한 요소로서 등장하게 되었다.

재밍의 목적은 전자전 환경에서 적이 전파를 자유롭게 이하는 것을 방해하는 것이다. 재밍은 통신정보의 송수신을 방해하는 통신 재밍과 항법 시스템, 레이더 등의 수신을 방해하는 비통신 재밍으로 구할 수 있다[1].

비통신 재밍 중에서 레이더 재밍은 항공기 선박, 지상 차량 등에서 미사일이나 유도탄 공격을 위한 적 레이더의 탐색, 추적 기능을 무력화시켜 적의 공격으로부터 방어하기 위한 자기방어 목적이 크다. 레이더 재밍은 초기 레이더의 주요 기능인 표적의 위치 파악 기능을 단순 방해하는 기술에서 적의 레이더를 통제하고 적이 모르게 반사파를 관리하는 은밀한 기만과 유인 기술로 발전해 오고 있다[1]. 레이더 재밍은 레이더 신호의 형태에 따라 즉 위협체계에 따라 다른 방법을 적용해야 한다. 또 일련의 적의 파격과정 중 한 개의 요소만을 방해하는 것보다 다수의 요소들을 방해하거나 약화시킴으로써 그 목적을 달성할 수 있다. 재밍 기술의 발전에 따라 적 레이더의 형태도 지속적으로 변화되고 또 개선되고 있다. 따라서 적의 위협 레이더 체계에 대응하기 위해서는 적의 레이더 성능 개선에 대비한 방해기술 능력을 지속적으로 향상시켜야 한다[1].

기존의 재밍기법은 장기간에 걸쳐 레이더 위협신호를 수집, 분석하고 이에 따른 위협 라이브러리를 기준으로 위협별 재밍기법을 할당하는 방식을 사용하였다[2]. 하지만 이 방법은 최신 위협이나 기존의 라이브러리에 존재하지 않는 위협에 대해서는 적절한 재밍기법을 할당하는데 제한이 따른다. 따라서 기존의 위협 라이브러리에 기반한 방식과 다르게 분석된 위협 신호의 데이터만을 이용하여 최적의 재밍기법을 지정할 수 있는 기술이 필요하다.

이 논문에서는 새로운 위협 신호에 대응하기 위한 방법으로, 기계학습 기법을 적용하여 기존에 축적된 라이브러리를 학습시킨 후, 실제 상황에

서는 분석된 위협 신호의 데이터만 이용하여 적응적으로 최적의 재밍기법을 생성하는 기법을 제안한다.

II. 본론

1. 기계학습을 위한 학습 데이터 생성

레이더 위협신호에 따른 라이브러리를 학습하기 위해 위협신호의 특성 중에서 레이더의 중요한 특성인 펄스의 중심주파수(radio frequency, RF)와 펄스 반복 간격(pulse repetition interval, PRI)을 사용하였다[2]. 주파수는 고정, 빠른 변화(agile), 도약(hopping), 정현파 패턴, -톱니파, +톱니파 등 6가지 유형의 변화 방식을 고려하였다. 또 PRI는 고정, 지터(jitter), 스태거(stagger), 체류 후 변경(dwell&switch), -톱니파, +톱니파 등 7가지 유형을 고려하였다[2]. 학습을 위해 이 두 가지 특징의 변화 방식, 최소값, 최대값, 단 수를 모두 불규칙적으로 다르게 하는 600개의 학습 데이터를 생성하게 된다.

2. 적응적 재밍기법 선택을 위한 기계학습

RF 값과 PRI 값으로부터 재밍기법을 선택하기 위한 시스템 구조는 그림 1과 같다.

먼저 학습 데이터의 입력으로부터 특징벡터를 추출하고, 이것을 양자화한 후 RF와 PRI의 형태에 따라 은닉 Markov 모델(hidden Markov model, HMM)을 학습시킨다. 일단 HMM을 학습시킨 후, HMM 결과와 재밍기법을 입출력 데이터로 하여 은닉층이 2개인 다층신경망을 학습시킨다.




그림 1 기계 학습 구조

특징벡터는 발생 데이터의 본래 값, 1차 차분값, 2차 차분값으로 구성된다. 특징벡터로서 차분값을 사용하는 이유는 HMM이 시간적인 변화를 잘 나타내기 때문이다.

RF와 PRI의 특징값은 K-means 알고리즘을 통해 양자화된다[3]. K-means 알고리즘은 재배치 기법의 일종으로 K개의 초기 중심점을 중심으로 K개의 클러스터가 될 때까지 분류를 반복한다. 알고리즘의 특성상 초기 중심점 및 클러스터 중심을 결정하는 방법에 따라 다른 분류 결과를 얻을 수 있다[3]. 이 알고리즘은 자율 학습의 일종으로, 입력 데이터에 레이블을 달아주는 역할을 수행한다. 전처리 한 특징 벡터를 K-means를 통해 양자화하고 이 값을 사용하여 HMM을 학습시킨다.

특징벡터를 양자화하는 것은 HMM의 상태 수를 제한하기 위함이다. HMM은 상태 수에 따라 계산량이 비례적으로 증가하는데, 상태 수는 입력 가짓수에 지수함수적으로 비례한다. 따라서 입력의 가짓수를 적절하게 조절할 필요가 있다.

HMM은 통계적 Markov 모델의 하나로, 시스템이 은닉된 상태와 관찰 가능한 결과의 두 가지 요소로 이루어졌다고 본다. 관찰 가능한 결과를 야기하는 직접적인 원인은 관측될 수 없는 은닉 상태들이고, 오직 그 상태들이 Markov 과정을 통해 표출된 결과만 관찰할 수 있다[4]. 이러한 HMM은 상태의 변화를 잘 나타내는 모델로서 어떤 물리량의 시간적인 변화를 모형화하는데 적합하다.

HMM은 RF와 PRI의 변화 형태 개수만큼 필요하며, 각 HMM에 대해 특정한 RF 또는 PRI 형태의 학습 데이터로 훈련을 시킨다. 이렇게 하면 임의의 데이터가 입력되었을 때 데이터의 RF 및 PRI 특성에 해당하는 HMM 출력만 1에 가까운 값을 나타내고, 나머지는 0에 가까운 값을 나타낸다.

일단 HMM 학습을 마친 다음, HMM 출력과 재밍기법을 임출력 쌍으로 하는 훈련 데이터를 이용하여 신경망[5]을 학습시킨다. 신경망은 2개의 은닉층과 1개의 출력층을 가지고 완전연결된(fully connected) 형태이다.

결과적으로 그림 1 전체 분류기의 입력은 특정 레이더의 RF와 PRI 값이 되고, 출력은 그에 해당하는 재밍기법이 된다.

3. 모의실험 결과

모의실험은 학습과 평가의 과정으로 구분된다. 전체 600가지의 레이더 데이터로부터 RF와 PRI 데이터를 생성한다. 이 중에서 무작위적으로 80%를 학습에 사용하고, 나머지 20%를 사용하여 분류기의 성능을 평가한다. 이 때 600개 각각에 대응되는 재밍기법의 전체 가짓수는 40이다.

표 1은 80% 선택, 20% 평가 과정을 10번 수행했을 때 분류를 잘못할 오분류 확률과 그 평균치를 나타낸다. 표에서 보면 오분류 확률은 최소 0.8%에서 최대 3.3%까지 나타난다.

표 2는 오분류 확률이 3.3%인 경우(모의실험 1)에 해당하는 신경망 출력값과 재밍기법을 나타낸다. 최대 출력값에 해당하는 재밍기법이 분류된 값이고, 밑줄친 값이 올바르게 분류된 경우에 해당한다. 대부분 두 번째 큰 값이 올바르게 분류된 경우에 해당한다.

오류가 발생하는 경우를 분석한 결과 HMM을 통해 RF와 PRI의 패턴 인식에 실패한 경우도 있고, 패턴은 제대로 인식하였지만 신경망에서 분류가 실패한 경우도 있었다. 실패한 경우는 대부분 입력값의 동적 범위가 매우 커서 K-means를 통해 양자화 될 때 구별이 없어지는 경우가 많았다.

표 1 10번 모의실험을 한 결과

모의실험	오분류 확률(%)
1	3.3
2	3.3
3	2.5
4	0.8
5	0.8
6	1.6
7	2.5
8	1.6
9	0.8
10	3.3
평균	2.0

표 2 오류가 발생한 경우의 신경망 출력값과 재밍기법

데이터 연번	347	371	361	349
재밍기법				
1	<u>0.4027</u>	-0.1860	<u>0.3458</u>	<u>0.5652</u>
2	<u>0.5972</u>	<u>0.2453</u>	<u>0.6503</u>	<u>0.4616</u>
3	0.0149	<u>0.9697</u>	0.0180	0.0155
4	-0.0197	-0.0563	-0.0190	-0.0601

III. 결론

이 논문에서는 기존의 재밍기법 할당 방식의 한계를 개선하기 위하여 HMM과 신경망으로 구성된 시스템에 기계학습을 적용한 적응형 재밍기법 선택 방법을 제안하였다. 학습 데이터는 위협신호의 특성 중에서 주파수와 펄스 간격을 사용하였다. 모의실험 결과 최대 약 4%의 오분류 확률을 나타내었다. 이 논문에서는 600개의 제한된 학습 데이터를 사용하였는데, 학습 데이터의 양을 증가시키고 매우 큰 동적 범위를 효과적으로 나타낼 수 있도록 전처리 과정을 개선하면 오류율을 줄일 수 있을 것으로 보인다.

ACKNOWLEDGMENT

이 연구는 국방과학연구소 위탁연구 지원으로 수행되었습니다.

참 고 문 헌

- [1] Sergei A. Vakin, Lev N. Shustov, Robert H. Dunwell, Fundamentals of Electronic Warfare, 2001.
- [2] Richard G. Wiley, ELINT: The Interception and Analysis of Radar Signals, 2006.
- [3] 이신원, 오형진, 안동연, 정성중, “한국어정보처리 : 클러스터 중심 결정 방법을 개선한 K-Means 알고리즘의 구현,” 정보처리학회논문지B, Vol. 11 No. 7, 2004.
- [4] Daniel Jurafsky, James H. Martin, Speech And Language Processing, 2000.
- [5] 박철웅, 이인범, 이병용, 박수봉, “다층신경망을 이용한 얼굴검색 알고리즘(The Facial Image Searching Algorithm using Multi-Layer Neural Networks)”, 한국멀티미디어학회, 1999