

기계학습 방법을 이용한 레이더 신호 분류

Classification of Radar Signals Using Machine Learning Techniques

홍 석 준*, 이 연 규*, 최 종 원*, 조 제 일**, 서 보 석*★

Seok-Jun Hong*, Yearn-Gui Yi*, Jong-Won Choi*, Jeil Jo**, Bo-Seok Seo*★

Abstract

In this paper, we propose a method to classify radar signals according to the jamming technique by applying the machine learning to parameter data extracted from received radar signals. In the present army, the radar signal is classified according to the type of threat based on the library of the radar signal parameters mostly built by the preliminary investigation. However, since radar technology is continuously evolving and diversifying, it can not properly classify signals when applying this method to new threats or threat types that do not exist in existing libraries, thus limiting the choice of appropriate jamming techniques. Therefore, it is necessary to classify the signals so that the optimal jamming technique can be selected using only the parameter data of the radar signal that is different from the method using the existing threat library. In this study, we propose a method based on machine learning to cope with new threat signal form. The method classifies the signal corresponding the new jamming method for the new threat signal by learning the classifier composed of the hidden Markov model and the neural network using the existing library data.

요 약

이 논문에서는 수신된 레이더 신호로부터 추출한 파라미터 데이터에 기계학습을 적용하여 그 레이더에 대응하기 위한 제밍기법에 따라 레이더 신호를 분류하는 방법을 제안한다. 현재 군에서는 대부분 사전 조사에 의해 구축된 레이더 신호 파라미터에 대한 라이브러리를 기반으로 위협 형태에 따라 레이더 신호를 분류한다. 그러나 레이더 기술은 계속적으로 발전되고 다양해지고 있기 때문에 새로운 위협이나 기존의 라이브러리에 존재하지 않는 위협형태에 대해서 이 방법을 적용하는 경우 적절하게 신호를 분류할 수 없고 따라서 적합한 제밍기법을 선택하는데 제한이 따른다. 따라서 기존의 위협 라이브러리를 이용한 방식과 다르게 추정된 레이더 신호의 파라미터 데이터를 이용하여 최적의 제밍기법을 선택할 수 있도록 신호를 분류하는 기술이 필요하다. 이 연구에서는 새로운 위협 신호의 형태에 대응하기 위한 방법으로 기계학습을 기반으로 한 방법을 제시한다. 제안한 방법은 기존에 축적된 라이브러리 데이터를 이용하여 은닉 마르코프(Markov) 모델과 신경망으로 구성된 분류기를 학습시킴으로써 새로운 위협 신호에 대해 적절한 제밍기법을 대응시킬 수 있도록 신호를 분류한다.

Key words : radar signal classification, jamming technique, machine learning, hidden Markov model, K-means

* Dept. of Electronics Engineering, Chungbuk National University

** Dept. Agency for Defense Development

★ Corresponding author

E-mail: boseok@cbnu.ac.kr, Tel: +82-43-261-3267

※ Acknowledgment

This research was supported by Agency for Defense Development and the intramural research grant of Chungbuk National University of 2015

Manuscript received Mar. 12, 2018; revised Mar. 15, 2018 ; accepted Mar. 19, 2018

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/3.0>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

I. 서론

현대전은 무선 전파를 사용하는 전자장비에 크게 의존하게 되면서 전자기술은 군사작전에서 점점 더 중요하게 되었고, 다양한 주파수 스펙트럼을 사용하는 복잡한 전자정보 환경에서 군사작전을 수행하게 되었다. 이와 같은 전자전 환경에서 적의 전파 이용을 제한하거나 무력화하는 재밍 기술이 전자방해책의 중요한 요소로서 등장하게 되었다[1].

재밍의 목적은 전자전 환경에서 적이 전파를 자유롭게 이용하지 못하도록 방해하는 것이다. 재밍은 통신정보의 송수신을 방해하는 통신 재밍과, 항법 시스템, 레이더 등의 수신을 방해하는 비통신 재밍으로 구분할 수 있다[1].

레이더 재밍은 비통신 재밍 중에서 가장 광범위하게 사용되는 방법으로 항공기 선박, 지상 차량 등에서 미사일이나 유도탄 공격을 위한 적 레이더의 탐색과 추적 기능을 무력화시켜 적의 공격으로부터 방어하기 위한 자기방어 목적이 크다. 레이더 재밍은 초기 레이더의 주요 기능인 표적의 위치 파악 기능을 단순 방해하는 기술에서 적의 레이더를 통제하고 적이 모르게 반사파를 관리하는 은밀한 기만과 유인 기술로 발전해 오고 있다[1]. 레이더 재밍은 레이더 신호의 형태에 따라 즉 위협 형태에 따라 다른 방법을 적용해야 한다. 또 일련의 적의 피격과정 중 한 개의 요소만을 방해하는 다수의 요소들을 방해하거나 약화시킴으로써 그 목적을 달성할 수 있다. 재밍 기술의 발전에 따라 적 레이더의 형태도 지속적으로 변화되고 또 개선되고 있다. 따라서 적의 위협 레이더 체계에 대응하기 위해서는 적의 레이더 성능 개선에 대비한 방해기술 능력을 지속적으로 향상시켜야 한다[1].

기존에는 재밍기법을 선택하기 위해 먼저 장기간에 걸쳐 레이더 위협신호를 수집, 분석하여 레이더 신호의 파라미터에 따라 레이더 신호를 분류한다. 그 다음 분류한 레이더 신호에 따라 그에 적합한 재밍기법을 할당한다. 이와 같은 일련의 과정을 라이브러리화 함으로써 레이더 신호의 파라미터만 추출되면 그로부터 해당하는 재밍기법을 선택할 수 있다[2]. 그러나 이 방법은 새로운 위협이나 기존의 라이브러리에 존재하지 않는

위협형태에 대해서는 적절한 재밍기법을 할당하는데 제한이 따른다. 따라서 기존의 위협 라이브러리에 기반한 방식과 다르게 분석된 위협 신호의 데이터만을 이용하여 최적의 재밍기법을 지정할 수 있도록 신호를 분류하는 기술이 필요하다.

이 논문에서는 새로운 위협 신호에 대응하기 위한 방법으로, 기계학습 방법을 적용하여 기존에 축적된 라이브러리를 학습시킨 후, 실전 상황에서는 분석된 위협 신호의 데이터를 이용하여 적응적으로 최적의 재밍기법에 해당하는 그룹으로 신호를 분류하는 방법을 제안하고자 한다.

II. 레이더 신호 분류 방법

이 논문에서 사용하는 레이더 신호는 짧은 펄스가 변조된 형태의 펄스 레이더 신호라고 가정한다. 펄스 레이더는 현대전에서 사용되는 레이더의 대부분을 차지한다. 수신된 신호를 분석하여 재밍방법을 선택하기 위한 기존의 신호분류는 그림 1과 같이 신호분석과 라이브러리에 의한 레이더 형태-재밍방법 대응 단계를 거친다[2].

신호분석은 레이더 신호의 파라미터 벡터 추출하는 단계와, 추출된 수십 ~ 수 백개의 파라미터 벡터를 분해하여 펄스에 대한 요약정보인 AET(active emitter table)를 생성하는 단계로 구분된다. 파라미터 벡터는 펄스의 중심주파수(radio frequency, RF), 펄스반복간격(pulse repetition interval, PRI), 펄스진폭, 펄스폭 등을 포함하는 파라미터로 구성된 벡터로 펄스설명어(pulse description word, PDW)라 한다[1]. 신호분석 단계의 출력인 AET는 각 파라미터의 최소/최대값과 변화 형태를 기술한 것이다. 레이더 형태에 재밍방법을 대응하기 위해서는 두 개의 라이브러리를 이용한다.




Fig. 1. Structure of the conventional radar signal classification method

그림 1. 기존의 레이더 신호 분류방법

먼저 AET로부터 레이더의 형태를 선택하고, 그 다음 선택된 레이더에 대해 적절한 재밍방법을 선택한다. 재밍방법을 선택한다는 것은 레이더 신호가 어떤 부류에 속하는지 분류하는 것과 동일하다.

III. 제안한 기계학습 기반 레이더 신호 분류 방법

수신한 레이더 신호로부터 파라미터 벡터를 추출하는 것은 매우 복잡한 신호분석이 필요하고[2] 재밍방법을 선택하기 위한 신호분류와는 별개의 분야이다. 따라서 이 논문에서는 파라미터 벡터 추출은 완료한 상태에서 레이더 신호를 분류하는 방법을 고려한다.

1. 기계학습을 위한 학습 데이터

이 논문에서는 레이더 위협신호에 따른 라이브러리를 학습하기 위해 위협신호의 특성 중에서 레이더의 가장 중요한 두 특성인 펄스의 RF와 PRI를 사용한다[2].

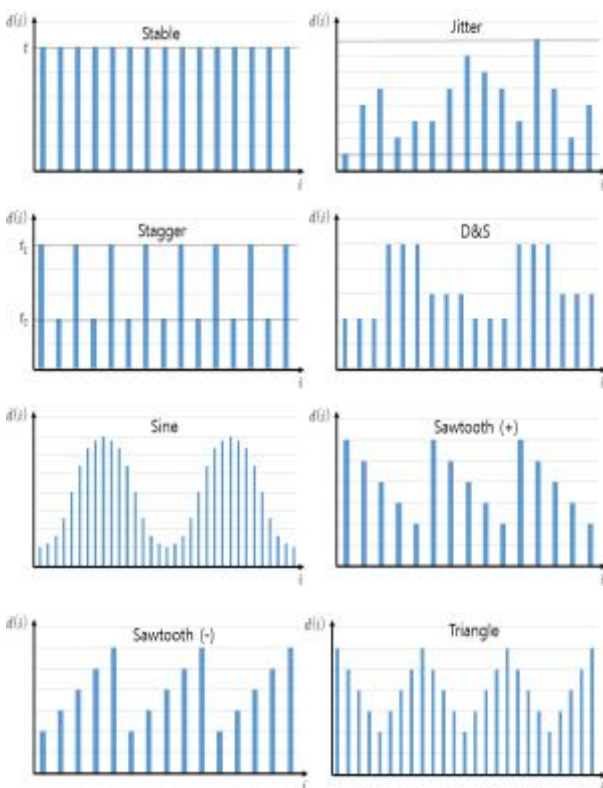


Fig. 2. Types of pulse repetition interval variation
그림 2. PRI 변화 형태

주파수는 시간에 따라 고정, 고속변화(agile), 도약(hopping), 정현파 패턴, -톱니파, +톱니파, 삼각파 등 7가지의 변화 형태를 고려한다. PRI는 고정, 지터(jitter), 스테거(stagger), 체류변경(dwell&switch), -톱니파, +톱니파, 삼각파 등 8가지 형태를 고려한다[2].

그림 2는 PRI의 8가지 변화 형태를 예를 들어 나타낸 것이다. 펄스의 RF 변화 형태 중에서 고속변화와 도약은 각각 PRI의 지터, 체류변경과 같은 형태이다.

2. 레이더 신호를 분류하기 위한 기계학습

RF 값과 PRI 값으로부터 신호를 분류하기 위한 제안 시스템의 구조는 그림 3과 같다. 먼저 RF와 PRI로 구성된 학습 데이터의 입력으로부터 특징벡터를 추출하고, 이것을 K-means 알고리즘에 따라 양자화한다. 그 다음 RF와 PRI의 변화 형태에 따라 각각의 은닉 Markov 모델(hidden Markov model, HMM)을 학습시킨다. 일단 HMM을 학습시킨 후, HMM 출력과 재밍기법을 입출력 데이터쌍으로 하여 은닉층이 2개인 다층신경망을 학습시킨다.




Fig. 3. Structure of radar signal classifier
그림 3. 신호분류기 구조

가. 특징벡터 추출

PRI의 변화 범위는 수 μs ~ 수 십 ms이고, RF는 수 GHz ~ 수 십 GHz로 동적범위가 매우 넓다[1]. 넓은 동적범위 내에서 PRI, RF의 변화 형태를 인식하기 위해서는 각 데이터의 최소값과 최대값의 범위를 0과 1 사이로 만드는 정규화 과정이 필요하다. 특징벡터는 RF, PRI의 본래 값, 1차 차분값, 2차 차분값으로 구성된다. 특징벡터로서 차분값을 사용하는 이유는 HMM이 시간적인 변화를 잘 모형화하기 때문이다[3].

나. K-means 알고리즘에 의한 양자화

RF와 PRI의 특징벡터는 K-means 알고리즘을 통해 양자화된다[4]. K-means 알고리즘은 무한한 개수의 입력값에 대해 유한한 K개의 값을 가지도록 양자화하는 방법이다. K-means 알고리즘은 K개의 초기값이 K개의 클러스터의 중심이 될 때까지 중심값 갱신과 분류를 반복한다. 알고리즘의 특성상 초기값과 클러스터 중심값을 결정하는 방법에 따라 다른 분류 결과를 얻을 수 있다[4]. 이 알고리즘은 자율학습의 일종으로, 입력 데이터에 유한한 개수의 레이블을 달아주는 역할을 수행한다.

특징벡터를 양자화하는 이유는 HMM의 상태 수를 제한하기 위함이다. HMM은 상태 수에 따라 계산량이 지수함수적으로 증가하는데, 상태 수는 입력 가짓수에 지수함수적으로 비례한다. 따라서 입력의 가짓수를 적절하게 조절할 필요가 있다. 이 논문에서는 실험을 통해 더 이상 성능이 크게 향상되지 않는 최소의 값으로 K값을 설정하였다[5].

다. HMM 학습

HMM은 통계적 Markov 모델의 하나로, 시스템이 은닉된 상태와 관찰 가능한 결과의 두 가지 요소로 이루어졌다고 본다. 관찰 가능한 결과를 야기하는 직접적인 원인은 관측될 수 없는 은닉 상태들이고, 오직 그 상태들이 Markov 과정을 통해 표출된 결과만 관찰할 수 있다[3]. 이러한 HMM은 상태의 변화를 잘 나타내는 모델로서 어떤 물리량의 시간적인 변화를 모형화하는데 적합하다.

HMM은 RF와 PRI의 변화 형태 개수만큼 필요하며, 각 HMM에 대해 특정한 RF 또는 PRI 형태의 학습 데이터로 훈련시킨다[6]. 이렇게 하면 임의의 데이터가 입력되었을 때 학습 시 적용한 RF와 PRI 특성에 해당하는 HMM 출력만 1에 가까운 값을 나타내고, 나머지는 0에 가까운 값을 나타낸다.

라. 다층신경망 학습

일단 HMM 학습을 마친 다음, HMM 출력과 제밍기법(또는 신호 부류)을 입출력쌍으로 하는 훈련 데이터를 이용하여 신경망을 학습시킨다.

신경망은 2개의 은닉층과 1개의 출력층을 가지고 완전연결된(fully connected) 형태이다.

결과적으로 그림 3 전체 분류기의 입력은 특정 레이더의 RF와 PRI 값이 되고, 출력은 그에 해당하는 제밍기법이 된다.

IV. 모의실험 결과

모의실험은 학습과정과 평가과정으로 구분된다. 레이더 가짓수는 600개와 7000개 두 가지 경우를 고려하였다. 이 중에서 무작위로 80%를 학습에 사용하고, 나머지 20%를 사용하여 분류기의 성능을 평가한다. 이 때 각 레이더에 대응되는 제밍기법의 전체 가짓수는 4이다. 각 레이더 데이터는 1000개의 PDW(RF와 PRI 값으로 구성)로 구성되어 있다.

표 1은 PDW의 오차율과 누락률이 0인 데이터에 대해 80% 학습, 20% 평가 과정을 10번 반복했을 때 제밍방법을 잘못 선택할 오분류 확률의 평균치를 나타낸다. 표에서 보면 오분류 확률은 레이더의 가짓수가 증가함에 따라 크게 감소하는 것을 볼 수 있다. 오분류가 발생하는 경우의 데이터를 분석한 결과, HMM을 통해 RF와 PRI의 변화 형태 인식에 실패하는 경우도 있고, 변화 형태는 제대로 인식하였지만 신경망에서 분류가 실패한 경우도 있었다. 실패한 경우는 대부분 입력값의 동적 범위가 매우 커서 K-means를 통해 양자화 될 때 구별이 없어지는(즉 동일한 값으로 양자화되는) 경우가 많았다.

Table 1. Performance of the proposed classifier

표 1. 제안한 분류기의 성능

Number of radar data	Average of misclassification rate(%)
600	6.1%
7000	1.8%

그림 4는 RF와 PRI 데이터의 오차율에 따른 오분류 확률을 나타낸다. 그림을 보면 600개 데이터의 경우 데이터의 오차가 증가하면 오분류 확률이 약간씩 증가한다. 그러나 7000개 데이터의 경우는 거의 변동이 없는 것을 볼 수 있다.

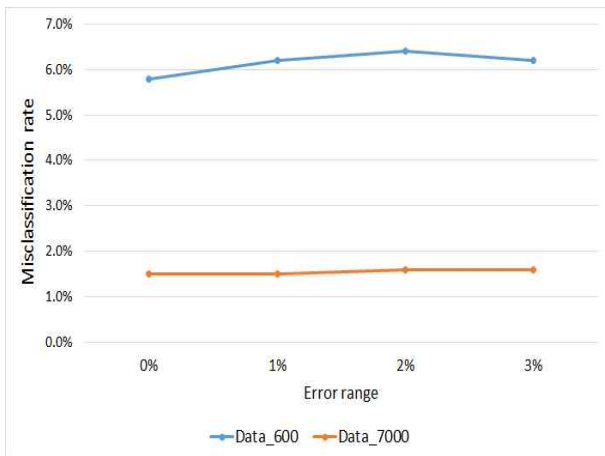


Fig. 4. Performance of the proposed classifier with the error rate of the PDW data

그림 4. PDW 데이터의 오차에 따른 제안 분류기의 성능

그림 5는 누락률에 따른 오분류 확률을 나타낸다. PDW가 누락되는 이유는 잡음, 다른 레이더 신호에 의한 간섭 등에 의해 레이더 펄스를 인식하지 못했기 때문이다. 600개 데이터의 경우 10% 누락률부터 서서히 오분류 확률이 증가하지만, 7000개 데이터의 경우는 20% 정도까지는 거의 그대로 유지하다가 30%에 이르러 오분류 확률이 증가한다. 실제 상황에서 PDW의 누락률은 최대 약 20% 정도 이므로, 7000개 정도의 데이터 수에서는 분류기의 성능이 누락률의 영향을 크게 받지 않는다고 볼 수 있다.




Fig. 5. Performance of the proposed classifier with the missing rate of the PDW data

그림 5. PDW 데이터의 누락에 따른 제안 분류기의 성능

V. 결론

이 논문에서는 기존의 재밍기법 할당 방식의 한계를 개선하기 위하여 K-means 및 HMM과 신경망으로 구성된 분류기를 제시하였다. 학습 데이터는 위협신호의 특성 중에서 펄스의 중심주파수(RF)와 펄스반복간격(PRI)을 사용하였다.

모의실험 결과 학습 데이터의 양이 증가할수록 오분류 확률이 감소하여, 7000개 데이터인 경우 약 2%의 오분류 확률을 나타내었다. 이 경우 오류율과 누락률이 증가함에 따라 오분류 확률은 거의 변화가 없음을 볼 수 있었다.

이 논문에서 각 레이더 데이터의 동적범위는 비교적 큰 값이었다. 오분류가 되는 경우는 이러한 큰 동적범위로부터 발생하는 것으로 분석되었다. 따라서 레이더의 데이터를 좀 더 세분화하여 동적범위를 줄이면 오분류 확률을 더 줄일 수 있을 것으로 판단된다.

이 논문에서 제안한 방법을 적용하면 전자전 환경에서 위협 레이더에 대응하여 재밍기법을 생성하고자 할 때 기존 위협 라이브러리에 존재하지 않는 새로운 위협신호에 대해서도 적절한 재밍기법을 대응시킬 수 있을 것이다.

References

- [1] Sergei A. Vakin, Lev N. Shustov, Robert H. Dunwell, *Fundamentals of Electronic Warfare*, Artech House, 2001.
- [2] Richard G. Wiley, *ELINT: The Interception and Analysis of Radar Signals*, Artech House, 2006.
- [3] Daniel Jurafsky, James H. Martin, *Speech And Language Processing*, Pearson Education, 2000.
- [4] Shin Won Lee, Hyung Jin Oh, Dong Un An, Seong Jong Jeong, "Korea Information Processing : An Implementation of K-Means Algorithm Improving Cluster Centroids Decision Methodologies," *The KIPS Transactions: Part B*, Vol. 11 No. 7, pp. 867-874, 2004.

[5] Sanghoon Jun, Eenjun Hwang, "Sequence-based Similar Music Retrieval Scheme," *j.inst.Korean.electr.electron.eng*, Vol.13 No. 2, pp. 167-174, 2009.

[6] In-Sung Woo, Chwa-Cheul Shin, Heung-Soon Kang, Suk-Dong Kim, "The Study of Korean Speech Recognition for Various Continue HMM," *j.inst.Korean.electr.electron.en g*, Vol. 11 No.2, pp. 89-94, 2007.

BIOGRAPHY

Seok-JunHong (Member)



2016 : BS degree in Semiconductor Engineering, CheongJu University.
2017~ : MS degree in Electronics Engineering, Chungbuk National University.

Yearn-Gui Yi (Member)



2000 : BS degree in Electronics Engineering, Chungbuk National University.
2000 : MS degree in Software Science, Chungbuk National University.

2008 : PhD degree in Control & Instrumentation Engineering, Chungbuk National University.

2000~2003 : Electronics and Telecommunications Research Institute(ETRI).

Jong-WonChoi (Member)



2014 : BS degree in Electronics Engineering, Chungbuk National University.
2016 : MS degree in Electronics Engineering, Chungbuk National University.

2016~ : PhD course in Electronics Engineering, Chungbuk National University.

JeilJo (Member)



2000 : BS degree in Electrical & Electronics Engineering, Kyungpook National University.
2005 : MS degree in Electronics Engineering, Kyungpook National University.

2005~ : Senior Researcher, Agency for Defense Development

Bo-SeokSeo (Member)



1987 : BS degree in Electronics Engineering, Seoul National University.
1989 : MS degree in Electronics Engineering, Seoul National University.

1997 : PhD degree in Electronics Engineering, Seoul National University.

2004~ : Professor, Chungbuk National University.